

“Predicción de malversaciones bancarias”

Autor/Autores: Chamorro Cayetano, Jorge Josue

Resumen - El presente trabajo aborda la problemática que enfrentan las entidades financieras en la detección de posibles malversaciones bancarias. Para ello, se plantea la implementación de un modelo predictivo usando técnicas de Machine Learning, con el objetivo de predecir la ocurrencia de dichas irregularidades.

1. Introducción

En la actualidad, debido al auge del uso de nuevas tecnologías, como bancas móviles, pagos electrónicos y billeteras digitales, las personas son cada vez más dependientes de estas herramientas tecnológicas. Como resultado, se ven expuestas a nuevos riesgos y métodos de hurto más innovadores. Esto se debe a que la ciberdelincuencia ha desarrollado, de manera consecuente, mayor conocimiento, mejores y, cada vez, menos identificables técnicas para las cuales las entidades financieras no tienen la preparación adecuada ni planes de contingencia.

Una de las principales amenazas es la apropiación indebida del bien capital personal, también conocida como malversación. La malversación tiene una alta tasa de ocurrencia debido a que los ciberdelincuentes toman ventaja de las vulnerabilidades de usuarios bancarios a su favor, como el desconocimiento técnico, desinterés en la evolución tecnológica o la excesiva confianza de las personas. En cuanto a la evolución tecnológica de los bancos, se siguen utilizando sistemas basados en la implementación de reglas, mediante sentencias SQL, que no detectan fidedignamente si una transacción ha sido fraudulenta. Esta tecnología obsoleta también se ha ido aprovechando por los ciberdelincuentes.

Dado el contexto explicado anteriormente, es importante la investigación presentada en este informe, ya que busca entender motores de reglas convencionales y aplicar técnicas de aprendizaje automático para agilizar, optimizar y mejorar la tecnología bancaria sobre la detección de fraudes. En otras palabras, se busca minimizar la cantidad de falsos positivos de fraudes, agilizar la detección de transacciones ilegales y contar con un sistema más robusto frente a la creciente ola de técnicas innovadoras de hurto cibernético.

1.1. Hipótesis y/o pregunta a abordar

La aplicación de modelos predictivos basados en inteligencia artificial permite anticipar la

ocurrencia de las malversaciones bancarias a clientes con más de 80% de precisión, siendo más eficiente y eficaz que el uso de métodos tradicionales como la detección reactiva.

1.2. Objetivos

Objetivo General

- Implementar un modelo predictivo de malversaciones bancarias utilizando técnicas de machine learning.

Objetivos Específicos

- Identificar patrones que impacten en la determinación de una transacción fraudulenta.
- Evaluar el desempeño de distintos algoritmos de machine learning para predecir las malversaciones.
- Comparar los resultados obtenidos con métodos tradicionales de detección.

2. Trabajos relacionados

Para la correcta realización de la investigación, se ha decidido abordar el estado del arte, buscando investigaciones recientes, dentro de los últimos años, que involucren aprendizaje de máquina.

Primeramente, la publicación: “Aplicación de Machine Learning a un modelo tradicional de Prevención y detección de fraude en entidad financiera proyectado a períodos trimestrales” [1], se centra en el fraude que afecta directamente a las industrias bancarias. Se especifica que “el fraude de pago en línea les cuesta a las empresas globales el 1,8% de los ingresos y no se trata solo del costo financiero, el fraude también afecta la reputación y fidelidad del cliente” (Quintero L., 2023, p. 15). A partir de esto, se menciona que el uso de inteligencia artificial solía ser bajo, a pesar de que era una tecnología con alta proyección en las empresas. Debido al uso de sistemas convencionales, se identifica que bajo reglas incorrectas o mal definidas se produce “una menor detección de fraude y falsos positivos” (Quintero L., 2023, p. 16); en otras palabras, se cuenta con sistemas poco ágiles y con resultados inconsistentes. En este contexto, Quintero L. establece que “el Machine Learning

se puede utilizar para detectar transacciones sospechosas o fraudulentas en tiempo real” (2023, p. 18), lo cual permitiría mejorar significativamente la capacidad de identificar casos de malversación bancaria.

Por su lado, en la publicación de la universidad EAN: “Análisis de métodos de machine learning para detección de fraudes en transacciones financieras en tiempo real” [2], se destaca el problema del fraude con herramientas sofisticadas, desde el punto de vista de las entidades financieras y los clientes. Se resalta que el origen de este problema está basado en el crecimiento del uso de plataformas digitales en Colombia (lo que nos permite extrapolarlo a otros países del continente sudamericano). Debido a que, a nivel de organización, el fraude representa miles de millones de dólares en pérdidas con un incremento cada vez más pronunciado en el tiempo, se plantea que la detección de estas transacciones fraudulentas debe ser preventiva y no reactiva.

La investigación realizada en esta publicación se basa en el análisis de “métodos actuales de detección de fraude en tiempo real mediante Machine Learning” (Tarazona M., 2025, p. 3). Con este objetivo es que se identifican las principales características, deficiencias y retos de estos métodos. Se analizan los sistemas basados en reglas, las técnicas de análisis estadístico, la auditoría con monitoreo manual, la autenticación con verificación de identidad, blacklisting y, finalmente, los modelos de machine learning (el cual presenta mayor cantidad de información y análisis).

Finalmente, en la publicación “A spatio-temporal prediction method based on GCN-BiLSTM for digital financial fraud risk” [3], el artículo aborda el desafío de predecir el riesgo de fraude financiero digital, considerando cualquier tipo de transacción financiera en entornos digitales. Señala que es un problema caracterizado por la complejidad de las correlaciones espacio-temporales presentes en los datos de las transacciones. Asimismo, menciona que los métodos tradicionales basados en reglas y modelos estadísticos muestran limitaciones, ya que no pueden adaptarse a la evolución de las tácticas de fraude ni manejar eficientemente datos de alta dimensionalidad.

Frente a este problema, los autores proponen un modelo de fusión espaciotemporal denominado GCN-BiLSTM, que integra Graph Convolutional Networks (GCN) y Bidirectional Long Short-Term Memory (BiLSTM) para capturar las dependencias estructurales entre transacciones como los patrones temporales

bidireccionales del comportamiento fraudulento. En este enfoque, GCN es utilizado para modelar las transacciones financieras representando a cada operación como un nodo y al flujo de capital como un enlace. Asimismo, BiLSTM es utilizado para analizar la evolución temporal de los datos en ambas direcciones atrás (pasado) o adelante (futuro) lo que permite identificar variaciones anómalas y patrones recurrentes en el tiempo.

De este modo, el modelo logró una fusión profunda entre las características espaciales y temporales, fortaleciendo la capacidad predictiva frente a los fraudes dinámicos. Por otro lado, para medir la efectividad del modelo, fue comparado con los enfoques tradicionales (Regresión Logística, Random Forest, SVM) y métodos de aprendizaje profundo (LSTM, GRU, GCN, EvolveGCN) utilizando métricas clave como *precision*, *recall* y *F1-score*. En base a los resultados, se concluye que GCN-BiLSTM constituye una solución eficaz.

En síntesis, los trabajos expuestos abordan la problemática de las transacciones fraudulentas. En ellos se evalúa la eficacia de su detección y prevención según diferentes contextos, comparando métodos tradicionales y aplicaciones de Machine Learning. Además, mediante el análisis de distintos algoritmos de aprendizaje y la identificación de ventajas y desventajas, se evidencia un alto desempeño en la predicción de comportamientos fraudulentos. De esta manera, los estudios constituyen una base teórica y metodológica sólida para el desarrollo del presente trabajo.

3. Metodología

Para definir la metodología a utilizar, se presenta la definición del problema: Sea X el conjunto de transacciones bancarias, cada una representada por un vector de características $x_i \in R^n$. El objetivo es obtener una función $f: R^n \rightarrow \{0,1\}$ que prediga si una transacción es fraudulenta (1) o legítima (0). Además, se muestra una gráfica de las etapas del ciclo de vida del modelo que se implementará:




Figura 01. Metodología seguida. Elaboración propia.

Dada la definición del problema, se puede proceder a definir el formato y comportamiento de los datos de entrada y salida.

Por un lado, el conjunto de los datos de entrada está compuesto por los siguientes atributos:

1. **trans_date_trans_time:** Fecha y hora exacta en que ocurrió la transacción.
 - a. Ejemplo: 2020-12-24 16:56:24
2. **merchant:** Nombre o identificador del comercio donde se realizó la compra.
 - a. Ejemplo: "Fraud_R_7614"
3. **category:** Tipo de comercio o industria.
 - a. Ejemplo: "gas_transport", "shopping_pos", "food_dining".
4. **amt:** Monto de la transacción en dólares.
 - a. Ejemplo: 57.86
5. **city:** Ciudad del cliente que realizó la transacción.
6. **state:** Estado/Región donde vive el cliente.
 - a. Ejemplo: "CA", "TX", "NY".
7. **lat:** Latitud aproximada de la ubicación del cliente.
8. **long:** Longitud aproximada de la ubicación del cliente.
9. **city_pop:** Población de la ciudad donde vive el cliente. Sirve para análisis demográficos o patrones de fraude en ciudades grandes o pequeñas.
10. **job:** Profesión del cliente.
 - a. Ejemplo: "Mechanical engineer", "Nurse".
11. **dob:** Fecha de nacimiento del cliente. Permite calcular su edad en el momento de la transacción.
12. **trans_num:** Número único o código identificador de la transacción. Sirve como primary key.
13. **merch_lat:** Latitud del comercio donde ocurrió la transacción.

14. **merch_long:** Longitud del comercio donde ocurrió la transacción.

Por otro lado, el conjunto de datos de salida está compuesto por un único resultado:

15. **is_fraud:** Etiqueta objetivo.
 - a. 0 significa transacción legítima.
 - b. 1 significa transacción fraudulenta.

La entrada fue seleccionada mediante una búsqueda exhaustiva de distintos conjuntos de datos por todo internet, páginas relacionadas a machine learning y repositorios en distintos controladores de versiones. Después de algún tiempo, se encontró el dataset "fraud_data.csv", el cual se analizará más a detalle en las siguientes secciones.

Luego, se ejecutó la etapa de preprocesamiento de los datos para determinar qué variables realmente resultaban necesarias y estadísticamente importantes para el estudio del desempeño del algoritmo. Asimismo, se requiere identificar o definir la relación de la variable "is_fraud" con las demás variables.

Con respecto al preprocesamiento, se realizaron ajustes como la conversión de los tipos de datos, limpieza de inconsistencias, verificación de correlaciones, escalamiento y encoding.

Una vez realizada la limpieza de los datos, se deben elegir los algoritmos a implementar para la evaluación de su desempeño. En este caso, se emplearán los siguientes algoritmos: "Regresión Logística" y "Random Forest". El algoritmo de Regresión logística fue elegido porque es ampliamente utilizado para variables de interés dicotómicas tal como ocurre en nuestro contexto con la variable "is_fraud". Se seleccionó el algoritmo de Árboles de decisión, específicamente de clasificación, ya que se trabajará con una variable cuantitativa transformada en valores binarios (0 y 1).

A continuación, se procede a realizar los experimentos conjuntamente con un porcentaje de los datasets. Para esto, se decidió utilizar solo el 70% de las transacciones u observaciones para el entrenamiento de los modelos y el 30% restante se utilice para la fase de testing o pruebas con el objetivo de medir el desempeño y comparar los algoritmos. También, se debe aclarar que la cantidad de datos positiva y negativa están desbalanceados, pero esto se observa cotidianamente en este tipo de problemática. En la siguiente sección, explicamos más acerca de esto.

Proporción común entre clase positiva y negativa




Figura 04. Transacciones totales.

Tomado de Quintero Acuña, L. K. (2023)

En los estudios que venimos desarrollando, se puede observar que los conjuntos de datos que utilizan no contienen tantos datos de clase positiva o, en palabras simples, datos de transacciones fraudulentas.

Detallando a profundidad, en el estudio de Quintero, se visualiza que el ratio entre las transacciones fraudulentas y las no fraudulentas es bajo, siendo este de 11.7%. A su vez, en el estudio de Tarazona, se detallan varios trabajos con distintos datasets en los cuáles podemos destacar que el porcentaje de clases positivas o fraudulentas es de 0,172% en el trabajo citado de Jovanovic et al., 2022. También, generalmente, se visualiza que todos los datasets de la Tabla 2 de este estudio, poseen una cantidad de transacciones fraudulentas muy baja con respecto a las clases negativas o no fraudulentas. Sin embargo, en la tercera publicación no dice exactamente el ratio del dataset, pero buscando por internet nos encontramos el propio conjunto de datos que utilizaron con las siguientes métricas:

Según la página Kaggle Elliptic Data Set, se indica lo siguiente:

“Nodes and edges. The graph is made of 203,769 nodes and 234,355 edges. Two percent (4,545) of the nodes are labelled class1 (illicit). Twenty-one percent (42,019) are labelled class2 (licit).”

En el que se aprecia, claramente, que 2% de los datos son de la clase positiva: fraudulentos.

Por todos estos porcentajes descritos anteriormente, optamos por utilizar un conjunto de datos con las siguientes métricas:

- Clase **positiva** (transacción fraudulenta) igual a un **87.22%** de toda la muestra.
- Clase **negativa** (transacción no fraudulenta) igual a un **12.76%** de toda la muestra.

Finalmente, cuando se haya implementado la solución, se utilizarán los resultados para definir qué algoritmo tuvo un mejor desempeño con respecto a la métrica Recall. Así, se podrá construir información importante para el desarrollo de las conclusiones y aportar en futuras decisiones sobre la detección de fraudes en el sector bancario.

4. Experimentación y Resultados

Para el análisis del dataset, se inició con un análisis descriptivo, pues los registros no presentan valores nulos. Se detectó que algunas variables, o columnas, como fechas, numéricas, cadenas de caracteres y números se presentaban como tipo de dato *object*; esta incongruencia no permite un análisis correcto de las variables. Por ello se realizó la conversión de cada una de estas variables a su tipo correspondiente, de *object* a *string*, *datetime*, *float* e *int*, en diferentes columnas.

Además, se encontraron inconsistencias en dos registros para la variable *is_fraud*, en los que en la columna *is_fraud* se encontraba el valor de la propia columna concatenada a una fecha. Estos registros fueron corregidos manualmente conservando únicamente el valor "0" o "1" de la columna *is_fraud*.

Posteriormente, se realizó una conversión de las columnas con tipo de dato Fecha, o *date*. Para la variable *trans_date_time*, que representa la fecha y hora exacta de la transacción, se decidió transformarla a una forma más sencilla utilizando únicamente el mes de la fecha. Esta transformación permitirá analizar los patrones temporales de manera general, posiblemente identificar periodos de mayor o menor frecuencia y evitar un sobreajuste en el modelo. Por otro lado, la variable *dob*, que almacena la fecha de nacimiento del cliente, fue utilizada para generar una nueva columna *edad*, que representa la edad del usuario al momento de la transacción, y posteriormente fue descartada la variable *dob* pues esta ya se encuentra inmersa en el atributo *edad*. Esta nueva variable facilitará el análisis de tendencias fraudulentas según grupos etarios, permitiendo identificar si algún o algunos rangos de edad enfrentan mayor riesgo a un fraude.

Luego, se realizó un conteo y análisis de la variable objetivo *is_fraud*. En este análisis se evidenció el desbalance presente en la distribución de clases del dataset a trabajar. La

proporción de casos fraudulentos no es cercana al 50% como se podría esperar; es decir, no se cuenta con un *dataset* con un balance ideal entre las clases. Ante esta situación, se decidió **no** alterar el *dataset* utilizando submuestreo ni sobremuestreo, ya que esto podría generar un comportamiento no representativo del mundo real; generando que el modelo prediga con mayor frecuencia los fraudes y por consecuencia se generen muchos falsos positivos. Adicionalmente, ante el *dataset* desbalanceado, es pertinente mencionar que “el uso de *Random Forest* es altamente recomendado para el aprendizaje con data desbalanceada” (Taghi M. 2007), así como también se recomienda el uso de *Logistic Regression* [5], por lo que es usual ver estos modelos en trabajos de índole parecida. Tras este análisis, se realizó un conteo de variables únicas, en el cual se identificó las inconsistencias de la variable *is_fraud*, previamente mencionado.

Continuando, se realizó el análisis de variables numéricas. El cual inició con la revisión de correlaciones como se muestra en la Figura 2. Durante la revisión se observó una alta correlación entre las variables *merch_lat* y *merch_long* con las variables *lat* y *long* de manera correspondiente, lo que se interpreta como la relación geográfica entre el lugar del comercio y el lugar en donde se realizó la transacción. Esto sugiere que un gran porcentaje de las transacciones se realizan en ubicaciones cercanas al comercio vinculado a la transacción. Posteriormente, se realizó un análisis general de los outliers; sin embargo, se decidió no eliminarlos, dado a que son estos valores atípicos los que justamente pueden representar una posible malversación.

Visualización de la matriz de correlación




Figura 02. Matriz de correlación. Elaboración propia.

Además, se aplicó un proceso de escalamiento de las variables numéricas usando *MinMaxScaler*. En cuanto a las variables categóricas, se procedió con la eliminación de la variable *trans_num*, debido a que no aporta valor predictivo en este análisis. El resto de parámetros categóricos fueron codificadas usando *LabelEncoder*, ya que al presentar una alta cantidad de valores únicos, se hubiera generado una gran dimensionalidad utilizando *OneHotEncoder*.

Pasada la etapa de preprocesamiento, se realizó la evaluación de los modelos seleccionados. Para ello, primero se realizó una división del *dataset*, usando un 30% para validación y utilizando 70% restante para el entrenamiento. Esta división resultó en un conjunto de entrenamiento conformado por 10,112 ejemplos, mientras el conjunto de prueba consta de 4,334. Luego, se definió la selección de pipelines de clasificación: *Logistic Regression* y *Random Forest*. Se utilizó la variable de score de **recall** para poder realizar la comparación del desempeño de los modelos, dado a que esta métrica permite reducir la ocurrencia de falsos negativos, es decir, los casos en que se identifique una transacción como no fraudulenta, cuando sí lo es.

Los resultados fueron bastante favorables; sin embargo, el rendimiento de *Random Forest* superó significativamente al de *Logistic Regression* (Ver Figura 02). *Logistic Regression* obtuvo un Recall de 0.4450 ± 0.1199 , mientras que *Random Forest* obtuvo 0.9176 ± 0.0880 .




Figura 03. Distribución de recall por modelo. Elaboración propia.

Estos valores indican que *Random Forest* cuenta con una mayor precisión de predicción, debido a la media del *recall*, y con una menor dispersión en su desempeño, debido a una menor desviación estándar; por lo cual se eligió este modelo como el modelo con mejor desempeño en esta comparación.

A partir de esta elección, se realizó una optimización de hiperparámetros, con el fin de

mejorar aún más el desempeño y eficiencia del modelo. Para ello, se evaluó 03 hiperparámetros representativos: *n_estimators*, *max_depth* y *max_features*. Luego de esta optimización, se determinó que los mejores valores para cada hiperparámetro corresponden a:

- *rfc__max_depth* = 30
- *rfc__max_features* = None (ninguna)
- *rfc__n_estimators* = 200.

Luego de entrenar nuevamente el modelo pero con dichas condiciones, se logró un incremento en el rendimiento, logrando un 95% de score en la métrica *recall*. Este valor se puede evidenciar con la matriz de confusión, donde de 507 transacciones fraudulentas, solo 25 fueron clasificadas incorrectamente (4.93%). Estos resultados se muestran en la Figura 03.




Figura 03. Matriz de Confusión del Random Forest. Elaboración propia.

5. Conclusión

En conclusión los resultados obtenidos permiten afirmar que los enfoques desarrollados responden de manera efectiva al problema planteado, la detección de malversaciones bancarias es un escenario donde las técnicas tradicionales basadas en reglas muestran limitaciones importantes, especialmente frente al desbalance natural de clases, complejidad de los patrones fraudulentos. En este contexto, los modelos de machine learning evaluados demostraron ser capaces de capturar relaciones y variaciones que los sistemas convencionales no identifican.

Asimismo, en relación a la hipótesis los resultados la respaldan de manera contundente. Ya que si bien la regresión logística mostró un desempeño bajo, el enfoque basado en Random Forest destacó significativamente, alcanzando un Recall de 0.9176 ± 0.0880 sin optimización de hiperparametros y con optimización un 95% de Recall, lo que permite verificar que el modelo detecta bien los fraudes. Por lo que se puede concluir que el enfoque basado en modelos de

machine learning resulta adecuado, sólido y altamente efectivo para abordar el problema. Asimismo el modelo se adapta a situaciones reales como desbalances o outliers, por lo que no es simplemente una alternativa frente a soluciones tradicionales sino que es una mejora sustancial.

6. Sugerencias de trabajos futuros

El presente trabajo constituye un primer acercamiento a la detección de malversaciones bancarias mediante modelos de aprendizaje automático. Si bien los resultados obtenidos muestran un desempeño prometedor, existen múltiples líneas de mejora que podrían fortalecer la precisión, la interpretabilidad y la aplicabilidad del sistema en escenarios reales.

En primer lugar, se recomienda profundizar en el preprocesamiento de datos. La transformación de variables como la edad y el mes de la transacción ha generado buenos resultados, evitando el overfitting, pero aún queda espacio para explorar nuevas representaciones temporales. Por ejemplo, diferenciar entre horarios laborales y no laborales, analizar patrones en fines de semana frente a días hábiles, o considerar la primera y segunda quincena del mes. Asimismo, incorporar fechas festivas y campañas comerciales podría ayudar a capturar tendencias estacionales de fraude que los modelos actuales no logran identificar con precisión.

Un aspecto crítico para trabajos futuros es la gestión del desbalance de clases. Los fraudes representan un porcentaje muy reducido de las transacciones totales, lo que puede afectar el desempeño del modelo. Se sugiere implementar técnicas de sobremuestreo (SMOTE, Synthetic Minority Oversampling Technique), submuestreo (RUS, Random Undersampling) de datos para equilibrar las clases y mejorar la sensibilidad del modelo frente a casos de fraude poco frecuentes.

Finalmente, se plantea la validación en entornos reales; probando el modelo con datos de instituciones financieras, bajo protocolos estrictos de anonimización y seguridad, permitiría evaluar su desempeño en condiciones de producción. Además, se recomienda diseñar mecanismos de actualización periódica del modelo para adaptarse a nuevas tácticas de fraude y considerar escenarios adversarios que simulan intentos de manipulación de datos por parte de ciberdelincuentes.

7. Implicancias éticas

El uso de modelos predictivos para detectar malversaciones bancarias plantea retos éticos

que deben atenderse antes de su implementación en entornos reales. Estos desafíos se relacionan con el manejo de datos sensibles, la posibilidad de sesgos en las predicciones, la protección de la privacidad y los riesgos derivados de decisiones automatizadas en el ámbito financiero.

En primer lugar, los datos empleados incluyen información delicada como la ubicación geográfica y los patrones de consumo de los clientes. Si no se aplican procesos adecuados de anonimización y encriptación, existe el riesgo de filtraciones que comprometan tanto la seguridad financiera como la integridad personal de los usuarios. Por ello, resulta indispensable establecer controles de acceso y auditorías periódicas sobre el uso de la información.

Otro aspecto crítico es el sesgo que puede introducir el modelo. Variables como la edad, la ciudad de residencia o la profesión podrían llevar a clasificaciones injustas, afectando a determinados grupos sociales. Esto podría traducirse en decisiones automatizadas que rechacen transacciones legítimas por considerarlas “fraudulentas”. Para evitarlo, es necesario evaluar cuidadosamente la relevancia de cada variable y realizar pruebas de equidad antes de poner el sistema en producción.

La transparencia también constituye un desafío. Muchos modelos de aprendizaje automático son percibidos como cajas negras, lo que dificulta comprender por qué una transacción fue marcada como fraudulenta. Incorporar mecanismos que expliquen qué factores influyen en cada decisión es clave para fortalecer la confianza de clientes y entidades financieras.

Asimismo, un exceso de falsos positivos puede deteriorar la relación con los usuarios. Bloquear operaciones legítimas de manera recurrente no solo genera molestias, sino que puede afectar la reputación de la entidad financiera. Una estrategia adecuada es combinar la detección automática con revisiones humanas y ofrecer canales de apelación o validación claros para los clientes.

Finalmente, debe considerarse la seguridad frente a ataques adversarios. Los ciberdelincuentes podrían manipular los datos de entrada para evadir la detección. Si el modelo no está preparado, estas vulnerabilidades podrían ser explotadas para facilitar fraudes. Por ello, se recomienda entrenar el sistema con escenarios simulados de ataque y mantenerlo actualizado frente a nuevas tácticas.

En resumen, garantizar la privacidad, reducir sesgos, ofrecer explicaciones claras y reforzar la seguridad son condiciones indispensables para que un modelo de detección de fraude aporte valor sin comprometer la confianza de los usuarios ni la integridad del sistema financiero.

8. Link del repositorio del trabajo

El trabajo fue elaborado en Google Colab: [fraud-detection-bank-transactions-ml.ipynb](#)

Presentación. [Predicción de malversaciones bancarias](#)

Github del proyecto: [fraud-detection-bank-transactions-ml](#)

Documentación del proyecto:

[W](#) [Predicción de malversaciones bancarias.do...](#)

9. Referencias

- [1]. Quintero Acuña, L. K. (2023). Aplicación de Machine Learning a un modelo tradicional de Prevención y detección de fraude en entidad financiera proyectado a períodos trimestrales. Disponible en: <https://hdl.handle.net/20.500.14625/16663>.
- [2]. Tarazona Nieto, M, Pérez Beltrán, D, Becerra Barajas, L y Mateus Agudelo, L. (2025). Análisis de métodos de machine learning para detección de fraudes en transacciones financieras en tiempo real. Universidad Ean. Disponible en: <http://hdl.handle.net/10882/14671>.
- [3]. Cui, S., & Zheng, L. (2025). *A spatio-temporal prediction method based on GCN-BiLSTM for digital financial fraud risk*. En 2025 IEEE 7th International Conference on Communications, Information System and Computer Engineering (CISCE). IEEE. Disponible en: <https://doi.org/10.1109/CISCE65916.2025.11065120>.
- [4]. Taghi, M., Golowala, M. & Hulse, J. (2007). *An empirical study of learning from imbalanced data using Random Forest*. En 2007 IEEE 19th International Conference on Tools with Artificial Intelligence (ICTAI) IEE. Disponible en: <https://ieeexplore.ieee.org/document/4410397>
- [5]. Maalouf, M. & Siddiqi, M. (2014). Weighted logistic regression for large-scale imbalanced and rare events data. En Knowledge-Based Systems. Disponible en: <https://doi.org/10.1016/j.knosys.2014.01.012>