





PREDICCIÓN DE MALVERSACIONES BANCARIAS



Autor: Chamorro Cayetano, Jorge Josue



CONTEXTO E INTRODUCCIÓN



PROBLEMÁTICA

El fraude digital crece y los sistemas bancarios actuales no los detectan bien.
Se necesitan métodos más modernos para identificarlo.

RELEVANCIA

Impacto económico y reputacional en entidades financieras

PROPUESTA DE SOLUCION


La aplicación de modelos predictivos basados en inteligencia artificial permite anticipar la ocurrencia de las malversaciones superando a los métodos tradicionales en detección de fraude

OBJETIVO GENERAL

Implementar un modelo predictivo de malversaciones bancarias utilizando técnicas de machine learning

OBJETIVOS ESPECÍFICOS

- Identificar patrones que impacten en la determinación de una transacción fraudulenta.
- Evaluar el desempeño de distintos algoritmos de machine learning para predecir las malversaciones.
- Comparar los resultados obtenidos con métodos tradicionales de detección.



TRABAJOS RELACIONADOS

APLICACIÓN DE MACHINE LEARNING A UN MODELO TRADICIONAL DE PREVENCIÓN Y DETECCIÓN DE FRAUDE EN ENTIDAD FINANCIERA [...]

Identificó que los sistemas tradicionales basados en reglas eran poco ágiles y generaban altos niveles de falsos positivos.

Demostró que el Machine Learning aplicado en tiempo real puede reducir significativamente esos falsos positivos y mejorar la detección de transacciones sospechosas.

Evidenció el impacto económico del fraude: pérdidas equivalentes al 1,8% de los ingresos globales y deterioro de la confianza del cliente.

Concluyó que la incorporación de ML en entidades financieras no solo mejora la precisión, sino que también fortalece la reputación y fidelidad de los clientes.



ANÁLISIS DE MÉTODOS DE MACHINE LEARNING PARA DETECCIÓN DE FRAUDES EN TRANSACCIONES FINANCIERAS EN TIEMPO REAL

Analizó el contexto colombiano y latinoamericano, mostrando cómo el crecimiento de plataformas digitales incrementa el riesgo de fraude.

Comparó métodos tradicionales (reglas, auditoría manual, autenticación, blacklisting) con enfoques de ML.

Concluyó que la detección preventiva en tiempo real es más eficaz que la detección reactiva, ya que permite bloquear fraudes antes de que se concreten.

Señaló que los modelos de ML ofrecen mayor capacidad de análisis y adaptabilidad frente a nuevas tácticas de fraude.

Propuso que las entidades financieras integren ML como parte de sus sistemas de monitoreo continuo para reducir pérdidas millonarias.



A SPATIO-TEMPORAL PREDICTION METHOD BASED ON GCN-BILSTM FOR DIGITAL FINANCIAL FRAUD RISK

Propusieron un modelo híbrido GCN-BiLSTM que combina redes convolucionales de grafos (para relaciones estructurales entre transacciones) y memorias bidireccionales (para patrones temporales).

Lograron capturar correlaciones espacio-temporales complejas, algo que los métodos tradicionales no podían manejar.

Compararon su modelo con enfoques clásicos (Regresión Logística, Random Forest, SVM) y otros de deep learning (LSTM, GRU, GCN, EvolveGCN).

Obtuvieron mejores métricas de precisión, recall y F1-score, mostrando que su enfoque es más robusto frente a fraudes dinámicos y cambiantes.

Concluyeron que la fusión espacio-temporal fortalece la capacidad predictiva y constituye una solución eficaz para entornos financieros digitales.



METODOLOGÍA

DEFINICIÓN DEL PROBLEMA

- $X = \{\text{transacciones bancarias}\}$
- Cada transacción bancaria es compuesto por un vector de características
- La función $f: R^n \rightarrow \{0,1\}$ busca predecir si una transacción es fraudulenta (1) o no

VARIABLES RELEVANTES Y SUS TRANSFORMACIONES

- trans_date_trans_time $\rightarrow$ mes
- trans_num $\rightarrow$ #eliminada
- amt
- merchant
- category
- city
- state
- job
- dob $\rightarrow$ edad
- lat – merch lat
- long – merch long
- is_fraud #variable objetivo : fraudulenta (1), objetivo (0)

ALGORITMOS


- Regresión Logística
- Random Forest

CARACTERÍSTICAS

- Datasets desbalanceados

MÉTRICA DE DESEMPEÑO

- Recall



EXPERIMENTACIÓN Y RESULTADOS

PREPROCESAMIENTO DE DATOS

Se corrigieron tipos de datos inconsistentes (fechas, strings, números).

Se transformaron variables clave:
dob → edad
trans_date_time → mes.

Se identificaron y corrigieron errores en la variable is_fraud.

CODIFICACIÓN Y ESCALAMIENTO

Variables numéricas escaladas con MinMaxScaler.

Se eliminó trans_num por no aportar valor predictivo.

Se codificaron las demás variables categóricas con Label Encoding

ANÁLISIS DEL DESBALANCE

El dataset presenta fuerte desbalance: pocos casos fraudulentos.


Se decidió no aplicar sub/sobremuestreo para preservar realismo.

Se eligieron modelos robustos frente a desbalance: Random Forest y Logistic Regression.

EVALUACIÓN DE MODELOS

División: 70% entrenamiento / 30% validación.


Métrica principal: recall, por su impacto para detectar falsos negativos.



ANÁLISIS DE CORRELACIONES

Alta correlación entre ubicación del comercio y del cliente.

Se conservaron outliers por su posible relación con fraudes.




OPTIMIZACIÓN Y DESEMPEÑO FINAL


Mejores hiperparámetros:
max_depth = 20
max_features = None
n_estimators = 100

Recall final: 95%

Solo 25 errores de clasificación en 532 fraudes.




CONCLUSIONES



Los algoritmos de machine learning evaluados demostraron ser capaces de capturar relaciones y variaciones que los sistemas convencionales no detectan, ya que a pesar de que la regresión logística demuestra un desempeño bajo, el RandomForest obtuvo un Recall de 0.9175 promedio y 95% luego de realizar la optimización de los hiperparametros, por lo que detecta casi perfectamente los fraudes financieros

El Random Forest implementado se adapta a situaciones reales como outliers y desbalances categóricos, por lo que no solo sería una alternativa frente a métodos tradicionales, sino que sería una mejora sustancial para resolver el problema.

SUGERENCIAS DE TRABAJOS FUTUROS




La gestión del desbalance de clases es clave. Se puede aplicar SMOTE o RUS de datos para equilibrar las clases y mejorar la sensibilidad del sistema frente a casos de fraude poco frecuentes.

Variables temporales más precisas permitirían detectar patrones estacionales y contextuales de fraude aún no capturados.



Validar el modelo en entornos reales, con seguridad y actualizaciones periódicas frente a nuevas tácticas de fraude.



IMPLICANCIAS ÉTICAS



Los datos sensibles requieren encriptación y controles de acceso para proteger la seguridad de los usuarios.

El modelo puede generar sesgos y clasificaciones injustas; se requieren pruebas de equidad antes de aplicarlo.




La transparencia es clave: explicar decisiones del modelo fortalece la confianza en su uso.



El modelo debe estar protegido contra ataques adversarios y actualizado frente a nuevas tácticas de fraude.



Un exceso de falsos positivos afecta la confianza; se requiere combinar detección automática con revisión humana




REFERENCIAS

Quintero Acuña, L. K. (2023). Aplicación de Machine Learning a un modelo tradicional de Prevención y detección de fraude en entidad financiera proyectado a períodos trimestrales. Disponible en: <https://hdl.handle.net/20.500.14625/16663>.

Tarazona Nieto, M, Pérez Beltrán, D, Becerra Barajas, L y Mateus Agudelo, L. (2025). Análisis de métodos de machine learning para detección de fraudes en transacciones financieras en tiempo real. Universidad Ean. Disponible en: <http://hdl.handle.net/10882/14671>.

Cui, S., & Zheng, L. (2025). A spatio-temporal prediction method based on GCN-BiLSTM for digital financial fraud risk. En 2025 IEEE 7th International Conference on Communications, Information System and Computer Engineering (CISCE). IEEE. Disponible en: <https://doi.org/10.1109/CISCE65916.2025.11065120>.



GRACIAS^{ME}

Linkedin: <https://www.linkedin.com/in/jorgechamorrocayetano/>

GitHub: <https://github.com/darkJCdark>

